

武汉大学国家网络安全学院

实验报告

课程名称 AI 程序设计实训（三）

专业年级 2024 级网络安全专业

姓名(学号) 刘子靖 2024302181142

敖心慧 2024302181151

潘冬冬 2024302181035

杨韵涵 2024302181144

叶宇灿 2024302181073

实验学期 2026 学年 3 学期

课堂时数 课外时数

填写时间 2026 年 7 月 10 日

实验概述

【实验项目名称】：基于循环神经网络的古诗词生成及优化实验

【实验目的】：

1. 理解字符级语言模型、循环神经网络与 LSTM 在文本生成任务中的基本原理，掌握“前缀序列预测下一个字符”的建模方式。
2. 复现参考仓库 `pytorch_peot_rnn` 的唐诗数据处理、模型训练和古诗生成流程，形成可运行的基础版本。
3. 对原始实现进行代码审计，识别训练/测试划分、模型选择、PAD 掩码、损失统计和生成接口等影响实验可信度的问题，并建立修正基线。
4. 围绕数据、模型、训练和评价四个方向做有依据的改进：数据侧完成清洗、去重、体裁标注和偏差分析；模型侧实现体裁条件因果注意力 LSTM；训练侧实现验证集选模、梯度裁剪、调度器和早停；评价侧设计非损失指标体系。
5. 比较 BaselineLSTM 与 ConditionalAttnLSTM 的实验结果，分析体裁条件、注意力结构和训练超参数对困惑度与收敛效果的影响。

【实验环境】（使用的软件）：

- (1) 硬件环境：各组员个人电脑，配置文件支持 CPU/CUDA 自动选择。
- (2) 操作系统环境：Windows 11
- (3) 测试脚本编程语言：Python 3.10/3.11；核心依赖包括 PyTorch、NumPy、Matplotlib、OpenCC、pypinyin 等。
- (4) 被测系统编程语言：Python
- (5) 网络环境：校园网，用于下载 GitHub 项目、Python 依赖和同步小组代码。
- (6) 其他环境：Git/GitHub 用于协作；YAML 配置用于实验可复现。

【参考资料】：

- [1] taishan1994. `pytorch_peot_rnn`[EB/OL]. GitHub:
https://github.com/taishan1994/pytorch_peot_rnn
- [2] PyTorch Documentation:
CrossEntropyLoss, AdamW, LSTM, clip_grad_norm_, ReduceLROnPlateau.

实验内容

【实验方案设计】：

1. 实验任务与总体设计

1.1 实验任务

本实验的输入为唐诗语料，输出为模型生成的古诗文本。整体任务采用字符级语言模型：将每个汉字视为一个 **token**，模型在给定前序字符的条件下预测下一个字符，训练后可用于普通续写、指定开头生成、藏头诗生成和体裁约束生成。小组工作不止于复现仓库，而是围绕“发现问题-修正基线-提出改进-控制变量实验-多维评价”形成闭环。

1.2 总体技术路线




图 1 总体流程图

1.3 实验研究问题

- RQ1: 原始唐诗数据在重复、体裁、作者、长度、低频字和简繁转换方面存在哪些问题？
- RQ2: 修正原仓库实验规范后，BaselineLSTM 的评价是否更可信？
- RQ3: 体裁条件 token 与因果注意力能否提升模型对标准体裁诗歌的建模能力？
- RQ4: AdamW、梯度裁剪、调度器、早停和 batch size 调整对收敛结果有何影响？
- RQ5: 仅用损失评价是否充分，如何建立格式、押韵、多样性、重复率和记忆风险等任务相关指标？

2. 原始仓库分析与基线复现

2.1 原仓库目录与运行流程

参考仓库的核心流程为：读取唐诗 JSON，执行文本清洗与繁简转换，按字符建立词表并加入特殊 token，将诗歌补齐为固定长度序列，使用两层单向 LSTM 训练下一个字符预测模型，最后通过贪心解码进行普通生成或藏头诗生成。

表 1 原仓库关键文件与功能说明

文件	原始作用	本实验处理
process.py	读取 JSON、清洗段落、生成 peot.txt/tang.npz	用于复现原始字符级数据处理；后续由 B 同学重写保留元数据的数据流水线。
model.py	定义 PoetryModel 与 PoetryModel2	主程序实际使用两层单向 LSTM；指出双向 LSTM 不适合自回归生成。
main.py	训练、测试、预测入口	审计发现测试集切片、测试集选模、生成函数全局变量等问题，建立修正基线。
config.py	保存训练/预测参数	保留复现说明；规范实验改用 configs/*.yaml。
README.md	给出运行方式和生成示例	作为原仓库复现结果的说明来源。

2.2 原始数据处理流程

原始流程以字符为建模单位：每首诗合并为一条字符串，词表中包含 PAD、UNK、SOP、EOP，输入为序列前 $T-1$ 个字符，目标为右移一位的后 $T-1$ 个字符。该方法实现简单，适合小规模实验，但原始 peot.txt 丢失了作者、题目、原始段落等元数据，限制了后续偏差分析。

2.3 原始模型结构




图 2 模型结构图

2.4 原仓库运行结果

参考仓库 README 中给出示例：以“丽日照残春”为开头可生成四句诗；以“深度学习”为藏头可生成每句首字依次对应输入文字的藏头诗。本实验在报告中保留该复现思路，但公平对比不直接使用原始结果，因为原仓库存在训练/测试划分和测试集选模问题。

2.5 原始代码审计与问题分析

表 2 原仓库实现问题与本实验修正方案

审计点	原始问题	修正方案
数据划分	原实现存在 train/test 切片重叠风险，容易造成测试集泄漏。	改为 data[train_total:], 并通过 hash 检查确认训练集、验证集、测试集无重叠。
模型选择	原实现倾向用测试集损失保存模型，测试集被间接参与调参。	只用验证集选择 best checkpoint, 测试集仅用于最终一次评价。
损失计算	PAD 位置若参与损失，会让长短诗样本比较失真。	CrossEntropyLoss(ignore_index=pad_id), 统计时剔除 PAD。
RNN 方向	双向 LSTM 不适合作为自回归生成主干，会看到未来信息。	采用单向 LSTM, 并在注意力层使用 causal mask。
训练稳定性	weight_decay、梯度爆炸、学习率调度等配置需在代码中真正生效。	使用 AdamW、gradient clipping、ReduceLROnPlateau 与早停。

3. 数据集分析与预处理

3.1 数据来源与数据格式

数据模块从 58 个 poet.tang.*.json 文件读取唐诗，保留 title、author、paragraphs、dynasty 等字段，新增 text、form 和 form_ids。相比原仓库只保存纯文本的做法，新数据流水线支持作者分布、体裁分布和噪声样本分析。

3.2 数据质量分析

表 3 数据质量问题与清洗处理统计

问题	表现	应对
重复样本	发现重复诗歌 1,129 首	基于纯汉字文本 MD5 hash 去除重复样本，避免训练/测试出现相同诗歌，夸大泛化效果
空文本/过短文本	空文本 13 首，过短文本 230 首	过滤，避免无意义或异常短文本干扰语言模型训练
长篇与非标准体裁	长篇/其他 20150 首，体裁混杂使模型难以学习固定句数和字数	本次训练主要保留标准近体诗，其他类型用于偏差讨论。

低频字长尾	低频字 2635 个，占 31.79%，异体字和专名较多，直接扩大词表会增加稀疏性。	保留高频词表并设置 UNK/PAD/SOP/EOP/体裁标记；说明罕见字生成能力有限。
作者偏置	Top 10 作者约占清洗语料 19.83%，高频作者风格更容易主导模型	报告中单独呈现 Top 作者图，结论不声称代表全部古诗风格。
文本规范化	抽样简体回繁不一致率 48.20%，繁简转换能降低词表规模，但可能损失历史字形信息。	OpenCC 统一处理，同时将规范化影响列入局限性。

3.3 体裁识别方法




图 3 体裁识别方法图

3.4 数据集划分

按 form_ids 分层划分 train/valid/test，比例 80%/10%/10%，总计 45,173 / 5,645 / 5,651。

表 4 数据集划分结果与重叠检查

form_id	体裁名称	train	valid	test
-1	其他/长篇	16120	2015	2015
0	五言绝句	3090	386	387
1	七言绝句	8333	1041	1043
2	五言律诗	11390	1423	1425
3	七言律诗	6240	780	781

划分后通过 hash 检查确认 $\text{train} \cap \text{valid} = 0$ 、 $\text{train} \cap \text{test} = 0$ 、 $\text{valid} \cap \text{test} = 0$ 。验证集用于模型选择、早停和超参数比较，测试集原则上只在最终模型确定后使用。

3.5 数据分布与偏差分析

最终有效数据为 56,469 首，标准体裁诗歌 36,319 首，占 64.3%。其中五言绝句 3,863 首、七言绝句 10,417 首、五言律诗 14,238 首、七言律诗 7,801 首。体裁分布并不均衡，五言律诗约为五言绝句的 3.7 倍，说明模型若不显式控制体裁，容易偏向训练集中更高频的长度和结构模式。




图 4 诗歌长度分布：清洗后数据长度中位数为 48，仍存在少量长篇样本。




图 5 体裁分布：五言律诗最多，五言绝句相对较少，体裁分布不均衡。




图 6 作者作品数量 Top 20：高产作者会影响模型学习到的风格和意象分布。

3.6 数据处理结果

表 5 清洗后语料规模、体裁与词表统计

项目	数量/比例	说明
原始诗歌	57,612 首	58 个 Tang JSON 文件
最终有效诗歌	56,469 首	去重和过滤后的 all_clean 数据
去重数量	1,129 首	约 2.0%
标准体裁诗歌	36,319 首	五绝、七绝、五律、七律
词表大小	6,403	训练词表含特殊 token 和真实字符
训练/验证/测试	45,173 / 5,645 / 5,651	分层划分，集合间无重叠

4. 修正基线模型设计

4.1 修正原则

修正基线保留两层单向 LSTM 主体，不加入体裁 token 和注意力，但使用统一训练框架中的 Dropout/LayerNorm。正确划分数据集，引入验证集，损失忽略 PAD，按有效 token 计算平均损失，使用验证集保存最佳模型，固定随机种子，并修复生成函数对全局变量的依赖。

4.2 模型结构




图 7 修正基线结构图

表 6 BaselineLSTM 模型结构与参数摘要

参数	设置
Embedding 维度	256
LSTM 层数	2
LSTM 隐藏维度	256
输出维度	vocab_size

4.3 前向传播过程

给定输入序列 $x = (x_1, \dots, x_T)$ ，Embedding 得到 e_t ，LSTM 递推得到隐藏状态 h_t ，线性层输出词表分布 logits_t 。训练目标为最小化目标序列 $y_t = x_{t+1}$ 的交叉熵。PAD 位置通过 `ignore_index=pad_id` 忽略，避免补齐字符参与梯度更新和指标统计。

5. 改进模型设计

5.1 原始 LSTM 存在的问题

- 原模型只看到字符序列，不知道用户希望生成五言、七言、绝句或律诗。
- LSTM 虽能建模上下文，但长距离跨句信息仍可能衰减。
- 贪心生成容易陷入高频字符和局部模式，导致重复和多样性不足。
- 双向 LSTM 在训练阶段可看到未来字符，不适合作为自回归生成模型的直接改进。

5.2 改进模型总体结构

最终改进模型采用 ConditionalAttnLSTM：在序列中加入体裁控制 token，经过 Embedding、Embedding Dropout、两层单向 LSTM 后，接因果自注意力层。注意力输出与 LSTM 输出进行残差连接，再经过 LayerNorm、Output Dropout 和 Linear 层预测下一个字符。该结构保持自回归因果性，同时增强当前位置对历史上下文的选择性关注。

表 7 ConditionalAttnLSTM 改进结构与设计作用

模型	参数量	体裁控制	因果注意力	说明
BaselineLSTM	4,337,923	否	否	修正基线，保留 dropout/layernorm，但不使用体裁条件和注意力
ConditionalLSTM	4,337,923	是	否	加入体裁 token，但结构与基线相同
ConditionalAttnLSTM	4,601,091	是	是	增加约 26.3 万注意力参数，作为主改进模型

5.3 体裁条件控制

数据集约定四个体裁 token：<5JUE>、<7JUE>、<5LV>、<7LV>，分别表示五言绝句、七言绝句、五言律诗和七言律诗。训练时 Dataset 会将体裁信息编码到输入序列中，使模型在生成前获得目标格式提示，从而学习不同体裁的长度、句数和标点分布。

5.4 因果注意力机制

注意力层对 LSTM 输出的历史隐藏状态重新加权。因果 mask 将当前位置之后的隐藏状态置为不可见，保证第 t 个位置只能关注 $1 \dots t$ 的信息，防止未来字符泄漏。与简单双向 LSTM 相比，因果注意力既能增强长距离依赖，又保持训练和生成阶段一致。

5.5 Dropout、残差连接与 LayerNorm

Embedding Dropout、LSTM Dropout 和 Output Dropout 用于缓解过拟合；残差连接保留原始 LSTM 表示，避免注意力层破坏顺序建模信息；LayerNorm 用于稳定隐藏状态分布，提高 RNN 训练稳定性。

6. 训练策略设计

训练部分由配置文件驱动，Baseline 与改进模型均记录 YAML、日志和曲线 CSV。最终权重文件 BEST_E4b_bs32.pt 保存了模型参数、优化器、调度器、词表、配置和训练/验证损失曲线，具备复现实验结果的必要信息。

表 8 训练策略与关键超参数配置

项目	修正基线/对照组	改进模型最佳配置
模型	BaselineLSTM	ConditionalAttnLSTM
batch size	64	32
learning rate	0.001	0.001
epoch	30	30
optimizer	Adam	AdamW
weight decay	0.0001	0.0001
gradient clip	1.0	1.0
scheduler	无或基础设置	ReduceLROnPlateau, factor=0.5, patience=2
early stopping	patience=5	patience=5
seed	2026	2026

RNN 训练容易出现梯度爆炸，因此在 `loss.backward()` 之后、`optimizer.step()` 之前进行 `clip_grad_norm_`，`max_norm=1.0`。改进模型使用 AdamW，使 `weight_decay` 配置实际生效；ReduceLROnPlateau 根据验证集损失长期不改善时降低学习率；Early Stopping 避免无意义训练和过拟合。

7. 古诗生成策略设计

本实验在 `src/generate.py` 中设计统一的 `PoetryGenerator`，用于连接训练完成的模型、字符词表与不同解码方法。生成时，模型根据已经生成的字符序列预测下一个字符的概率分布，并重复执行该过程，直到生成结束标记或达到设定的最大长度。

为了避免模型输出无实际意义的控制符，生成阶段会屏蔽 `PAD`、`UNK`、`SOP` 等特殊 `token`，并在必要时加入重复 `n-gram` 限制，降低连续输出相同字符或重复短语的概率。在此基础上，生成模块支持贪心生成、`Temperature` 调节、`Top-k` 采样、`Top-p` 采样、格式约束和藏头诗生成。不同策略共享相同的模型参数，其主要区别在于如何从模型输出的字符概率分布中选择下一个字符。

7.1 贪心生成

贪心生成在每个时间步直接选择当前概率最高的字符，即：

$$x_t = \arg \max_v P(v | x_1, x_2, \dots, x_{t-1})$$

该方法不包含随机采样，因此在模型参数和输入提示相同的情况下，每次生成结果均保持一致，具有稳定、可复现和便于模型对比的优点。本实验将贪心生成作为基础解码方式，用于观察 `BaselineLSTM` 与 `ConditionalAttnLSTM` 在相同条件下的生成差异。

贪心策略的不足在于，每一步只保留局部概率最大的字符，容易持续选择高频字词，使生成结果趋于保守。在较长序列中，还可能出现意象单一、句式重复以及文本多样性不足等问题。因此除贪心解码外，本实验还设计了带随机性的 `Top-k` 和 `Top-p` 采样策略。

7.2 Temperature

`Temperature` 用于调节模型输出概率分布的平滑程度。生成前，将原始 `logits` 除以温度参数 T ，再通过 `Softmax` 得到新的概率分布：

$$P(x_i) = \text{Softmax}\left(\frac{z_i}{T}\right)$$

当 $T < 1$ 时，概率分布更加集中，模型更倾向于选择高概率字符，生成文本通常较稳定，但多样性较弱；当 $T > 1$ 时，候选字符之间的概率差距缩小，低概率字符获得更多被选择的机会，生成结果更丰富，但也更容易出现语义跳跃或不通顺现象。

因此，`Temperature` 并不是完全独立的生成方法，而是与 `Top-k`、`Top-p` 等采样方法配合使用的调节参数。实验中可通过统一提示词和随机种子比较不同温度设置，观察稳定性与多样性之间的权衡。

7.3 Top-k 采样

Top-k 采样首先从模型预测结果中选出概率最高的 k 个候选字符，将其余字符的概率置零，再对保留的候选字符重新归一化并进行随机采样。

与贪心生成相比，Top-k 不再固定选择唯一的最高概率字符，因此能够提高生成文本的多样性；同时，它又排除了大量低概率候选，能够减少完全不相关字符被选中的风险。参数 k 较小时，生成结果更接近贪心策略；参数 k 较大时，候选范围更广，随机性也更强。

该方法适合用于普通古诗续写和同一提示词下的多样化生成，但固定的 k 值不能根据不同上下文自动调整候选集合规模。

7.4 Top-p 采样

Top-p 又称核采样。该方法将所有候选字符按照预测概率从高到低排序，并依次累加概率，直到累计概率达到设定阈值 p 。随后只在这一动态候选集合中进行随机采样。

与 Top-k 固定保留若干候选不同，Top-p 的候选数量会随上下文变化。当模型对下一个字符判断较确定时，只需保留少量高概率候选；当概率分布较平缓时，候选集合会自动扩大。因此，Top-p 在保持主要语义方向的同时，通常能够获得比贪心生成更丰富的表达。

本实验将 Top-p 作为多样化生成的重要方法，并与 Temperature 配合控制输出的随机程度。为了保证实验结果可比较，正式评价时应固定提示词集合、采样参数、最大生成长度和随机种子。

7.5 格式约束生成

仅依靠字符概率采样，模型不能保证输出严格符合五言绝句、七言绝句、五言律诗或七言律诗的格式。为此，本实验根据目标体裁加入格式约束，使生成过程同时受到模型概率和形式规则控制。

格式约束首先根据目标体裁确定句数和每句汉字数。例如，五言绝句要求四句、每句五个汉字，七言律诗要求八句、每句七个汉字。生成过程中在规定位置插入逗号和句号，并在普通字符位置屏蔽 PAD、UNK、SOP 等特殊 token。若某一字符或 n -gram 在当前诗歌中短时间内反复出现，则降低其再次被选择的概率，缓解循环重复问题。

该方法能够直接提高生成诗歌的形式规范性，但约束过强也可能限制模型自由选择字符的空间。因此，格式约束主要用于可控体裁生成，并结合流畅性、多样性和人工评价判断其整体质量。

7.6 藏头诗生成

藏头诗生成要求每一句的首字按照顺序对应用户给定的文字。例如，输入“深度学习”时，生成诗歌四句的首字应依次为“深”“度”“学”“习”。

实现时，生成器先读取用户提供的藏头字符串，并根据目标句数确定需要使用的首字。在生成每一句的第一个字符时，不进行概率采样，而是直接将对应藏头字加入当前序列；句内剩余位置仍由模型按照指定解码策略生成。完成一句后插入相应标点，再进入下一句。

这一方法将用户输入转化为明确的结构控制信号，能够展示模型的可控生成能力。藏头诗生成结果除检查整体语言质量外，还需要通过藏头成功率确认各句首字是否正确匹配输入文字。

8. 评价方法设计

古诗生成不仅是下一个字符预测任务，还涉及句数、字数、押韵、语言流畅性、内容多样性和文学风格等多个方面。因此，训练损失或困惑度只能反映模型对测试序列的拟合能力，不能单独代表生成诗歌的整体质量。

本实验在 `src/metrics.py` 中设计自动评价指标，并由 `scripts/evaluate.py` 统一加载模型、测试集、生成样本和训练集文本。评价脚本接入正式 `checkpoint` 后，可输出模型层指标、生成质量指标、评价结果文件和生成样例。

8.1 困惑度

困惑度用于衡量语言模型对测试序列的预测能力。本实验先计算所有非 `PAD` 位置上的平均负对数似然，再取指数：

$$\text{PPL} = \exp\left(\frac{\text{非 PAD token 的负对数似然之和}}{\text{非 PAD token 总数}}\right)$$

`PPL` 越低，说明模型对测试字符序列的预测越确定。与原仓库直接累加 `batch loss` 的方法相比，按有效 `token` 数进行归一化，可以减少 `batch size` 和序列补齐比例对结果的影响。

但困惑度只反映字符预测能力。一个 PPL 较低的模型仍可能生成重复、缺乏意境或不符合格律的诗歌，因此本实验不将其作为唯一评价标准。

8.2 下一字符准确率

下一字符准确率统计模型在测试集中正确预测目标字符的比例。计算时先取得每个位置 logits 中概率最高的字符，再与目标字符比较，同时使用有效位置掩码排除 PAD：

$$\text{Accuracy} = \frac{\text{非 PAD 位置预测正确数}}{\text{非 PAD 位置总数}}$$

该指标直观反映模型的字符级预测能力，可与 PPL 相互补充。但准确率同样不能反映完整诗歌的格式、语义和审美质量，因此只作为模型层辅助指标。

8.3 格式正确率

格式正确率用于判断生成诗歌是否符合指定体裁的基本结构。评价程序首先按照中文逗号和句号划分诗句，再检查句数、每句汉字数和标点位置。

五言绝句应包含四句且每句五个汉字；七言绝句应包含四句且每句七个汉字；五言律诗与七言律诗则分别要求八句五字和八句七字。只有句数、字数和标点均满足目标体裁要求时，才将该样本判定为格式正确。

格式正确率能够直接评价体裁 token 和格式约束生成是否发挥作用，但形式正确并不意味着诗歌在语义和文学性上同样合理。

8.4 近似押韵一致率

古诗通常在偶数句句末形成一定的押韵关系。本实验使用 pypinyin 获取偶数句末字的普通话拼音韵母，并比较这些韵母是否一致或近似一致，以此计算近似押韵一致率。

对于绝句，主要比较第二句和第四句末字；对于律诗，可进一步比较第二、第四、第六和第八句末字。该指标能够提供一定的形式评价依据，但现代普通话读音与中古音、平水韵等古典韵部并不完全一致。因此，本实验将其称为“近似押韵一致率”，不将其解释为严格的古典押韵正确率。

8.5 Distinct-1 和 Distinct-2

Distinct 指标用于评价生成文本的多样性。Distinct-1 计算生成样本中不同字符数占全部字符数的比例，Distinct-2 计算不同二元字符组合占全部二元组合的比例：

$$\text{Distinct-2} = \frac{\text{不同二元组数量}}{\text{二元组总数}}$$

指标越高，说明生成结果使用的字符或局部组合更加丰富。需要注意的是，过高的多样性也可能来自不合理或不连贯的字符组合，因此 **Distinct** 需要与格式正确率、重复率及人工判断结合分析。

8.6 重复率

循环神经网络在自回归生成过程中可能陷入局部高概率模式，从而反复生成相同字符、词组或句式。本实验从连续重复字符、重复 **bigram**、重复 **n-gram** 和句间重复等角度识别这一问题。

连续重复字符反映“人人”“不不”等直接重复；重复 **bigram** 和 **n-gram** 用于发现相同短语在一首诗中多次出现；句间重复则检查不同诗句是否存在大面积相同内容。重复率越高，通常说明模型的生成模式越单一。

生成器中的重复 **n-gram** 限制用于缓解这一问题，而重复率指标用于比较加入限制前后的实际变化。

8.7 新颖性与训练集重合度

生成模型可能直接复现训练语料中的整首诗或较长片段，因此只检查文本是否流畅还不足以判断模型是否真正具有生成能力。本实验将生成诗歌与训练集文本进行比较，重点检查完全重合和局部高重合两类情况。

完全重合度统计生成诗歌与训练集中某首诗完全相同的比例；局部重合度则通过 **4-gram** 等字符片段比较，判断生成结果是否大量复用了训练样本。完全重合或高比例长片段重合可能表明模型存在记忆训练数据的风险。

该指标的目标不是禁止使用常见古诗词语，而是识别整首复制或大段复制现象。分析时应结合具体相似样例，避免把“春风”“明月”等常用意象误判为模型记忆。

8.8 人工评价

自动指标难以完整评价古诗的意象、风格和整体审美，因此可以补充匿名人工评价。建议对相同提示词下不同模型生成的诗歌进行随机编号，隐藏模型名称，由多名评价者分别从语言流畅性、语义连贯性、意象合理性、古诗风格、格式规范性和整体质量六个维度进行 1~5 分评分。

评价时应保证不同模型使用相同的提示词集合和相近的生成数量，并汇总各维度平均分。如果最终报告提交前仍未完成正式人工评分，则应保留本小节作为评价方案，但不能在实验结果中填写虚构分数，也不应声称已经完成匿名人工评价。

9. 实验设置与变量设计

9.1 实验变量

- 自变量：数据处理、模型结构、训练策略、生成策略；
- 因变量：困惑度、格式正确率、Distinct、重复率；
- 控制变量：数据划分、词表、随机种子、训练轮数或早停规则。

9.2 实验组与超参数设置

表 9 实验组设置与控制变量

编号	数据	模型	训练策略	目的
E1	清洗/统一划分数据	BaselineLSTM	Adam, lr=0.001, batch=64	建立可信修正基线
E3	同上	ConditionalAttnLSTM	AdamW, lr=0.001, batch=64	验证体裁条件和注意力模型收益
E4a	同上	ConditionalAttnLSTM	AdamW, lr=0.0005, batch=64	比较学习率影响
E4b	同上	ConditionalAttnLSTM	AdamW, lr=0.001, batch=32	当前最佳模型配置
E4c	同上	ConditionalAttnLSTM	AdamW, lr=0.001, batch=64, epoch=50	观察延长训练是否继续提升

10. 成员分工

表 10 小组成员分工与模块产出

成员	负责方向	主要产出
刘子靖	复现与审计	复现参考仓库流程，整理原始实现问题，为 baseline 修正提供依据。
叶宇灿	数据模块	完成语料清洗、去重、体裁识别、划分、词表构建和数据统计图表；输出 data_module_readme.md 。
潘冬冬	模型模块	实现 BaselineLSTM 、 ConditionalLSTM 、 ConditionalAttnLSTM ，统一前向接口和生成所需状态。
杨韵涵	训练实验	维护 baseline.yaml / improved_model.yaml ，完成 E1/E3/E4a/E4b/E4c 训练，提交日志、曲线 CSV 和最佳权重。
敖心慧	评价与报告	整合权重和日志，运行最终 evaluate ，完成多维评价、结果解释、图表统一和最终报告。

【实验结果与结论】：

1. 数据处理结果

数据清洗并未大量损失有效样本：原始数据 57,612 首，最终有效 56,469 首，删除主要来自重复、空文本和过短文本。标准体裁诗歌 36,319 首，占 64.3%，足以支撑体裁条件生成实验；但体裁不均衡、作者分布偏斜和低频字长尾仍是模型训练和评价时必须说明的限制。

2. 训练日志结果

表 11 各实验组验证集最优结果对比

编号	模型	训练配置	最佳 Epoch	Valid Loss	Valid PPL
E1	BaselineLSTM	lr=0.001, bs=64, Adam, 30 epoch	30	4.514119	91.30
E3	ConditionalAttnLSTM	lr=0.001, bs=64, AdamW, 30 epoch	30	4.253404	70.34
E4a	ConditionalAttnLSTM	lr=0.0005, bs=64, AdamW, 30 epoch	30	4.294121	73.27
E4b	ConditionalAttnLSTM	lr=0.001, bs=32, AdamW, 30 epoch	30	4.238262	69.29
E4c	ConditionalAttnLSTM	lr=0.001, bs=64, AdamW, 50 epoch	47	4.239347	69.36

从日志看，E4b 是当前最优实验：验证困惑度从 baseline 的 91.30 降至 69.29，下降约 24.1%；验证损失下降 0.2759。E4c 延长到 50 轮后最佳点在第 47 轮，但 Valid PPL=69.36，略差于 E4b，说明继续训练并未带来稳定收益；E4a 的较小学习率更稳但收敛不足。

Validation Perplexity Comparison




图 8 验证集困惑度曲线：改进模型整体显著低于 baseline，E4b 取得最优验证 PPL。




图 9 最佳模型 E4b 的训练/验证损失曲线：验证损失在第 30 轮达到 4.2383。

3. 消融与超参数分析

E4a 学习率降低反而略差，E4c 延长训练收益不明显，E4b batch size=32 最好。

表 12 消融与超参数实验结果分析

对比	现象	解释
E1 -> E3	PPL 91.3 降至 70.4	改进模型结构和 AdamW 训练策略显著提升建模能力
E3 -> E4a	学习率 0.0005 使 PPL 升至 73.3	学习率过低导致 30 epoch 内收敛偏慢
E3 -> E4b	batch 64 改为 32 后 PPL 降至 69.2	较小 batch 带来更频繁更新和一定正则化效果
E4b -> E4c	50 epoch 的 PPL 约 69.4，与 E4b 接近	训练收益趋于饱和，延长训练提升有限

4. 最终 checkpoint 测试集评价

获得权重后，使用 checkpoints/BEST_E4b_bs32.pt 在测试集上重新运行 scripts/evaluate.py。测试集包含 5,651 首诗，评价脚本加载 6,403 大小的训练词表和 E4b 配置，得到 test loss=4.23836、test PPL=69.294142、test accuracy=0.293798。

表 13 不同生成策略评价指标

策略	格式	D-1	D-2	重复二元组	训练 4-gram	唯一率
----	----	-----	-----	-------	-----------	-----

greedy	1.000	0.214	0.386	0.614	0.1515	0.500
topk	1.000	0.411	0.932	0.0679	0.0284	1.000
topp	1.000	0.559	0.980	0.0196	0.0152	1.000
constrained	1.000	0.429	0.954	0.0464	0.0189	1.000

四种解码策略的 **test loss/PPL/Acc** 相同，因为它们使用同一个最终模型和同一测试集；差异体现在生成样例。**Greedy** 生成最稳定，但重复二元组率高达 **0.614**，且唯一率仅 **0.5**；**Top-p** 的 **Distinct-1/2** 最高、重复率最低、训练 **4-gram** 重合最低，更适合展示多样化生成。




图 10 生成策略指标对比：Top-p 在多样性、重复控制和训练集重合度综合表现最好。

5. 生成样例

表 14 不同解码策略生成样例与简评

策略	体裁/提示	生成结果	简评
greedy	五绝 / 春	春风吹柳絮，春色满江边。不是江南客，相思不可怜。	格式完整，语义连贯，但“春”字重复明显。
greedy	七绝 / 山	山中有客不相逢，一片云霞一片峰。今日不知何处去，白云深处是人踪。	意象集中，整体最像传统绝句。
topk	五绝 / 春	春月正新霁，江风吹柳条。不堪游处远，独自向东遥。	画面自然，多样性优于 greedy。
topp	七绝 / 山	山南路险自东西，始见灵岩寺里啼。万仞高峰千里绿，黄霞朝月出窗迷。	意象更发散，个别语义连接略弱，但重复少。

6. 实验结论

(1) 可复现性：最终报告中的核心数字均来自当前仓库日志、checkpoint 和 evaluate 输出；最优权重为 BEST_E4b_bs32.pt。

(2) 有效性：ConditionalAttnLSTM 相比修正 baseline 将验证 PPL 从 91.30 降至 69.29，说明体裁条件、自注意力和规范训练策略有效。

(3) 评价：Top-p 解码在样例多样性、低重复和低训练 4-gram 重合方面优于 greedy，适合作为最终展示策略。

【小结】：

1. 实验收获

本实验使小组完整经历了从参考代码复现到可信实验构建的过程。我们不仅实现了字符级 LSTM 古诗生成，也学会了先审计原始实现、再建立修正基线、最后在数据、模型、训练和评价四个方向做有依据的改进。尤其是数据偏差分析和非损失评价体系，使实验不再停留在“能跑通”，而是具备了可解释、可复现和可讨论的研究价值。

2. 遇到的问题及解决方法

表 15 实验问题、解决方案与改进效果总结

问题	原因	解决方法
原仓库评估不可信	训练/测试切片重叠，测试集用于选模	重新划分 train/valid/test，验证集用于选模
数据缺少元信息	原仓库保存为纯文本 peot.txt	从原始 JSON 保留作者、题目、段落和体裁字段
RNN 容易过拟合和梯度不稳定	长序列训练与小数据长尾	使用 Dropout、LayerNorm、AdamW、梯度裁剪和 early stopping
只用损失不能评价诗歌质量	PPL 不等于文学质量	设计格式、押韵、多样性、重复、记忆和人工评价指标
成员代码接口可能不一致	数据、模型、训练各自开发	约定 batch dict 和 logits [B,T,V] 统一接口

3. 实验局限

- 当前模型仍是字符级模型，缺少词语、典故和主题层面的显式知识。
- 普通话拼音韵母只能近似评价押韵，不能等同于严格古典韵部。
- 数据集主要覆盖唐诗，不能代表全部古典文学体裁。
- 格式正确不等于文学质量高，自动指标必须结合人工评价和案例分析使用。

4. 后续改进方向

- 引入平水韵或古典韵书资源，替代普通话拼音韵母的近似押韵评价。
- 加入主题、作者或意象控制，提升可控生成能力。
- 尝试预训练语言模型或 Transformer 对比实验，分析 RNN 方法的优势和局限。
- 进行作者/朝代/体裁分组测试，定量观察数据偏置对生成风格的影响。

指导教师评语及成绩

【评语】：

成绩：

指导教师签名：

批阅日期：

附件：

实验报告说明

- 1. 实验项目名称：**要用最简练的语言反映实验的内容。要求与实验指导书中相一致。
- 2. 实验目的：**目的要明确，要抓住重点，符合实验任务书中的要求。
- 3. 实验环境：**实验用的软硬件环境（配置）。
- 4. 实验方案设计（思路、步骤和方法等）：**这是实验报告极其重要的内容。包括概要设计、详细设计和核心算法说明及分析，系统开发工具等。应同时提交程序或设计电子版。

对于**设计型和综合型实验**，在上述内容基础上还应该画出流程图、设计思路和设计方法，再配以相应的文字说明。

对于**创新型实验**，还应注明其创新点、特色。
- 5. 结论（结果）：**即根据实验过程中所见到的现象和测得的数据，做出结论（可以将部分测试结果进行截屏）。
- 6. 小结：**对本次实验的心得体会，所遇到的问题及解决方法，其他思考和建议。

7. 指导教师评语及成绩：指导教师依据学生的实际报告内容，用简练语言给出本次实验报告的评价和价值。